



Wyznaczenie przedziału czasowego powstania budynków na podstawie ortofotomapy z użyciem narzędzi głębokiego uczenia

PRACA DYPLOMOWA MAGISTERSKA

Promotor: dr inż. Adam Inglot

Autor: inż. Kamil Rakowski



Wstęp

Automatyczna detekcja zabudowań

Wyznaczenie przedziału czasowego

Wyniki

Wnioski



**W pracy dyplomowej przedstawiono metodę
pozyskania danych wektorowych, zawierających
informacje o kształcie i położeniu budynków, na
podstawie ortofotomapy**



Celem pracy jest wyznaczenie przedziału czasowego powstawania budynków na podstawie ortofotomapy wykorzystując do tego narzędzia głębokiego uczenia.



Przed przystąpieniem do opracowania wyników wykonano:

- 1. Przegląd literatury**
- 2. Pozyskanie danych z Geoportalu Krajowego**
- 3. Przygotowanie oprogramowania do wykonania koniecznych analiz**



Wybór obszaru do opracowania dobrano biorąc pod uwagę cztery główne czynniki:

- 1. Dostępność danych w kolejnych latach.**
- 2. Jakość danych (rozdzielczość terenowa piksela).**
- 3. Zauważalność zmian w ilości i układzie zabudowań na przestrzeni lat.**
- 4. Rodzaj zabudowań występujących na obszarze.**

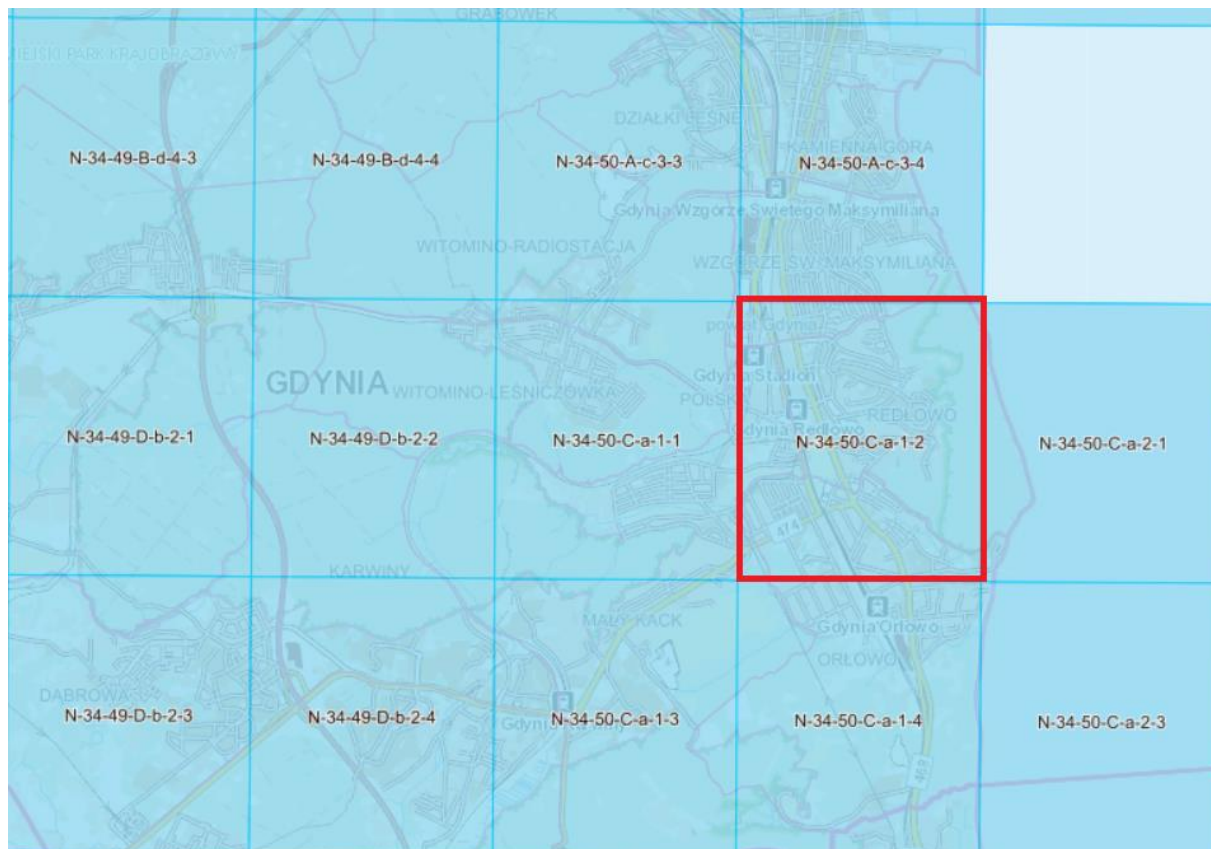


Arkusz N-34-49-B-d-2-3 znajduje się w północno-zachodniej części powiatu Gdynia, obręby ewidencyjne, które zawiera to Chylonia, Cisowa, Pogórze.





Arkusz N-34-50-C-a-1-2 znajduje się w południowo-wschodniej części powiatu Gdynia, w pobliżu Zatoki Gdańskiej, obręby ewidencyjne, które zawiera to Redłowo, Orłowo, Wzgórze Św. Maksymiliana i Mały Kack.





Arkusz N-34-49-D-b-1-2 znajduje się w południowo-zachodniej części powiatu Gdynia, obręby ewidencyjne, które zawiera to Chwarzno-Wiczlino





Zakres czasowy opracowania:

- **Dla wybranego obszaru możliwe do pobrania były ortofotomapy dla roczników 2004, 2010, 2013, 2016, 2017, 2019, 2020, 2021.**
- **Wytycznych nie spełniały dane dla lat 2004, 2010 oraz 2016, które posiadały zbyt małą rozdzielczość a dodatkowo w 2004 roku nie było kompozycji RGB.**



Arkusze ortofotomapy wykorzystane w opracowaniu:

Numer	Godło ortofotomapy	Rocznik	Pixel Depth	Rozdzielczość terenowa
1	N-34-49-B-d-2-3	2013	8 Bit	0,10m
		2017*	8 Bit	0,05m
2	N-34-50-C-a-1-2	2019	8 Bit	0,25m
		2020	8 Bit	0,25m
3	N-34-49-D-b-1-2	2021	8 Bit	0,25m

* Ortofotomapa z roku 2017 została pobrana w czterech mniejszych arkuszach



Narzędzia geoprzetwarzania „*Detect Objects Using Deep Learning*” w oprogramowaniu ArcGIS umożliwia przeprowadzanie analiz metodami głębokiego uczenia.



Przed przystąpieniem do pracy z danymi, należało skonfigurować środowisko. W tym celu niezbędne było:

- **Sprawdzenie specyfikacji i kompatybilność procesora graficznego (GPU),**
- **Instalacja CUDA (Compute Unified Device Architecture),**
- **Instalacja ArcGIS Pro wraz z bibliotekami Python dla uczenia głębokiego.**



Wstęp

Automatyczna detekcja zabudowań

Wyznaczenie przedziału czasowego

Wyniki

Wnioski



- Narzędzie „*Detect Objects Using Deep Learning*” wykorzystujące algorytmy oparte na konwolucyjnych sieciach neuronowych oraz modelu uczącym dostępnym na stronie producenta, pozwala na wykrywanie obiektów klasyfikowanych przez algorytm jako budynki.
- Wyznacza ich obwiednie tworząc poligony odpowiadające obrysom dachów i zapisuje je do nowej warstwy wektorowej.



Przed rozpoczęciem właściwego opracowania wykonano testy pracy narzędzia, które pozwoliły na wybór ustawień oraz modelu uczącego najlepiej przystosowanych do wybranego obszaru.



**POLITECHNIKA
GDAŃSKA**

WYDZIAŁ INŻYNIERII LĄDOWEJ
I ŚRODOWISKA

AUTOMATYCZNA DETEKCJA ZABUDOWAŃ

Porównanie modeli uczących



USA



Afryka



Australia




**Po wykonaniu 115 prób na
3 różnych arkuszach
ortofotmapy wybrano
parametry narzędzia
dające najlepsze wyniki**

Model Definition	usa_building_footprints
padding	2
batch_size	3
threshold	0,75
return_bboxes	False
tile_size	768
Non Maximum Suppression	Yes



Porównanie wyników uzyskiwanych z różnymi ustawieniami parametrów





- **Wykrywane budynki zapisywane były jako poligony o nieregularnych kształtach**
- **Do celów analizy przekształcono je w obiekty lepiej odpowiadające graficznej reprezentacji budynków tj. z prostopadłymi bokami.**



**POLITECHNIKA
GDAŃSKA**

WYDZIAŁ INŻYNIERII LĄDOWEJ
I ŚRODOWISKA

AUTOMATYCZNA DETEKCJA ZABUDOWAŃ

Przed przekształceniem:



Po przekształceniu:





Wstęp

Automatyczna detekcja zabudowań

Wyznaczenie przedziału czasowego

Wyniki

Wnioski



- Do porównanie danych użyto narzędzia „*Detect Feature Changes*”, które działa wyłącznie z obiektami liniowymi
- Obiekty powierzchniowe przekonwertowano w liniowe
- Porównano, czy w roku poprzednim w sprawdzanym miejscu występował budynek.



**POLITECHNIKA
GDAŃSKA**

WYDZIAŁ INŻYNIERII LĄDOWEJ
I ŚRODOWISKA

WYZNACZENIE PRZEDZIAŁU CZASOWEGO

Przed konwersją:




Po konwersji:






Działanie narzędzia „*Detect Feature Changes*”



Output with CHANGE_TYPE values





Wykryte zmiany w latach 2013 - 2017





**POLITECHNIKA
GDAŃSKA**

WYDZIAŁ INŻYNIERII LĄDOWEJ
I ŚRODOWISKA

WYZNACZENIE PRZEDZIAŁU CZASOWEGO

Wykryte zmiany w latach 2017 - 2019





**POLITECHNIKA
GDAŃSKA**

WYDZIAŁ INŻYNIERII LĄDOWEJ
I ŚRODOWISKA

WYZNACZENIE PRZEDZIAŁU CZASOWEGO

Wykryte zmiany w latach 2019 - 2020





**POLITECHNIKA
GDAŃSKA**

WYDZIAŁ INŻYNIERII LĄDOWEJ
I ŚRODOWISKA

WYZNACZENIE PRZEDZIAŁU CZASOWEGO

Wykryte zmiany w latach 2020 - 2021





Do zoptymalizowania metody napisano skrypt w języku Python, który pozwala na przeprowadzenie procesu porównawczego w sposób półautomatyczny.



Wykorzystane moduły biblioteki arcpy:

- 1. arcpy.ia.DetectObjectsUsingDeepLearning**
- 2. arcpy.RegularizeBuildingFootprint_3d**
- 3. arcpy.PolygonToLine_management**
- 4. arcpy.DetectFeatureChanges_management**
- 5. arcpy.MakeFeatureLayer_management**
- 6. arcpy.SaveToLayerFile_management**



- **Dane wektorowe pozyskane z ortofotmapy dla roku 2021 porównano również z danymi BDOT10k,**
- **Warstwa BUBD_A zawiera informacje o budynkach,**
- **Jest to warstwa poligonowa, dlatego wykonano przekształcenie do warstwy liniowej**



Jako wynik porównania otrzymano warstwę liniową zawierającą atrybuty:

- **S – dla budynków, które były w BDOT10k, ale nie zostały wykryte na ortofotomapie,**
- **NC – dla budynków, które były w obu porównywanych warstwach,**
- **N – dla budynków wykrytych w procesie detekcji, których nie ma ich BDOT10k.**



- **Wszystkich warstwy zawierające wyniki wyeksportowano do plików CSV,**
- **Tabela wynikowa zawiera informację o roczniku powstania, położeniu i powierzchni obiektu, ufności z jaką został znaleziony na bazie ortofotomapy.**



Wygląd tabeli wynikowej

OBSZAR 1 - N-34-49-B-d-2-3					
ID	Year of const.	Area [m2]	Centroid X [m]	Centroid Y [m]	Confidence [%]
1824	2014-2017	182	465155	742093	79.1949
1812	2014-2017	189	464837	742098	80.0523
1811	2014-2017	167	464936	742103	80.4152
1819	2014-2017	110	464969	742108	81.7551
1820	2014-2017	20	464997	742114	78.7755
1818	2014-2017	22	465036	742122	86.4826
1810	2014-2017	30	464844	742127	84.2765
1809	2014-2017	31	464924	742139	86.3467
1825	2014-2017	467	465373	742130	99.3388
1710	2014-2017	33	464823	742163	77.8611
1706	2014-2017	32	464822	742174	82.9204
1705	2014-2017	64	464878	742178	89.9507
1795	2014-2017	82	465560	742179	84.2571
...
16	2014-2017	921	465280	744436	78.0872
58	2014-2017	677	465383	744436	76.5911
69	2014-2017	1064	465598	744436	84.8692
STATYSTYKI					
Ilość:	221	Rok:	2014-2017	Średnia ufność:	87.8132
1445	2018-2019	49	465454	742121	76.1730

OBSZAR 2 - N-34-50-C-a-1-2					
ID	Year of const.	Area [m2]	Centroid X [m]	Centroid Y [m]	Confidence [%]
2166	2014-2017	23	471318	735122	85.3712
2155	2014-2017	397	471064	735117	97.0878
2169	2014-2017	106	471543	735130	84.8355
2153	2014-2017	38	470852	735136	85.7767
2157	2014-2017	153	471073	735138	92.8099
2141	2014-2017	73	470676	735143	97.9761
2173	2014-2017	564	471675	735131	86.7729
2168	2014-2017	884	471428	735131	96.4367
2116	2014-2017	88	471512	735155	76.5362
1986	2014-2017	96	470223	735156	89.4055
2030	2014-2017	75	470674	735178	92.4812
1968	2014-2017	306	470222	735189	99.4632
1994	2014-2017	696	470425	735181	98.0235
...
174	2014-2017	599	471021	737440	84.9156
175	2014-2017	596	471212	737440	88.8752
173	2014-2017	974	470855	737440	90.3427
STATYSTYKI					
Ilość:	209	Rok:	2014-2017	Średnia ufność:	88.9124
1864	2018-2019	111	470679	735110	76.4785

OBSZAR 3 - N-34-49-D-b-1-2					
ID	Year of const.	Area [m2]	Centroid X [m]	Centroid Y [m]	Confidence [%]
1146	2014-2017	21	463151	735172	76.6926
1143	2014-2017	27	463135	735173	85.8599
1123	2014-2017	890	462523	735169	95.9398
1132	2014-2017	28	462983	735176	85.3592
1156	2014-2017	19	463408	735178	76.1042
1130	2014-2017	28	463061	735179	89.9972
1154	2014-2017	24	463349	735180	86.9045
1133	2014-2017	28	463030	735180	85.2874
1128	2014-2017	24	462943	735183	91.4163
1155	2014-2017	25	463373	735183	80.1650
1139	2014-2017	36	463196	735184	96.0504
1153	2014-2017	28	463420	735186	88.6939
1131	2014-2017	32	462974	735187	88.5625
...
49	2014-2017	39	462886	737487	92.8988
32	2014-2017	16	462155	737499	84.3955
11	2014-2017	1518	461544	737421	87.6688
STATYSTYKI					
Ilość:	203	Rok:	2014-2017	Średnia ufność:	90.8991
833	2018-2019	46	463283	735301	84.5579



Wstęp

Automatyczna detekcja zabudowań

Wyznaczenie przedziału czasowego

Wyniki

Wnioski



Porównując dane z roku 2021 z danymi BDOT10k dla tego samego obszaru otrzymano:

- **N-34-49-B-d-2-3: 1281 obiektów wykrytych przy 1518 obiektach w bazie danych wektorowych, tj. 237 obiektów więcej w BDOT10k**
- **N-34-50-C-a-1-2: 1735 obiektów wykrytych przy 1900 obiektach w bazie danych wektorowych, tj. 165 obiektów więcej w BDOT10k**
- **N-34-50-D-b-1-2: 926 obiektów wykrytych przy 934 obiektach w bazie danych wektorowych, tj. 8 obiektów więcej w BDOT10k**



Średnia ufność wyznaczenia budynków w porównaniu z BDOT10k


Obszar / Typ zmiany	N-34-49-B-d-2-3	N-34-50-C-a-1-2	N-34-50-D-b-1-2
Wykryte obiekty	1281	1735	926
N	141	97	46
NC	993	1422	685
S	147	228	195
Dokładność	77,5%	82,0%	74,0%



- **Średni wynik ufności wykrycia dla wszystkich analizowanych obszarów wyniósł 77,8%.**
- **Jako parametr wejściowy w procesie detekcji, niepewność wyznaczania budynków przyjęto na poziomie 75%.**
- **Liczby te różnią się o niecałe 3 punkty procentowe. Jest to zadowalający dokładnościowy wynik całego procesu.**

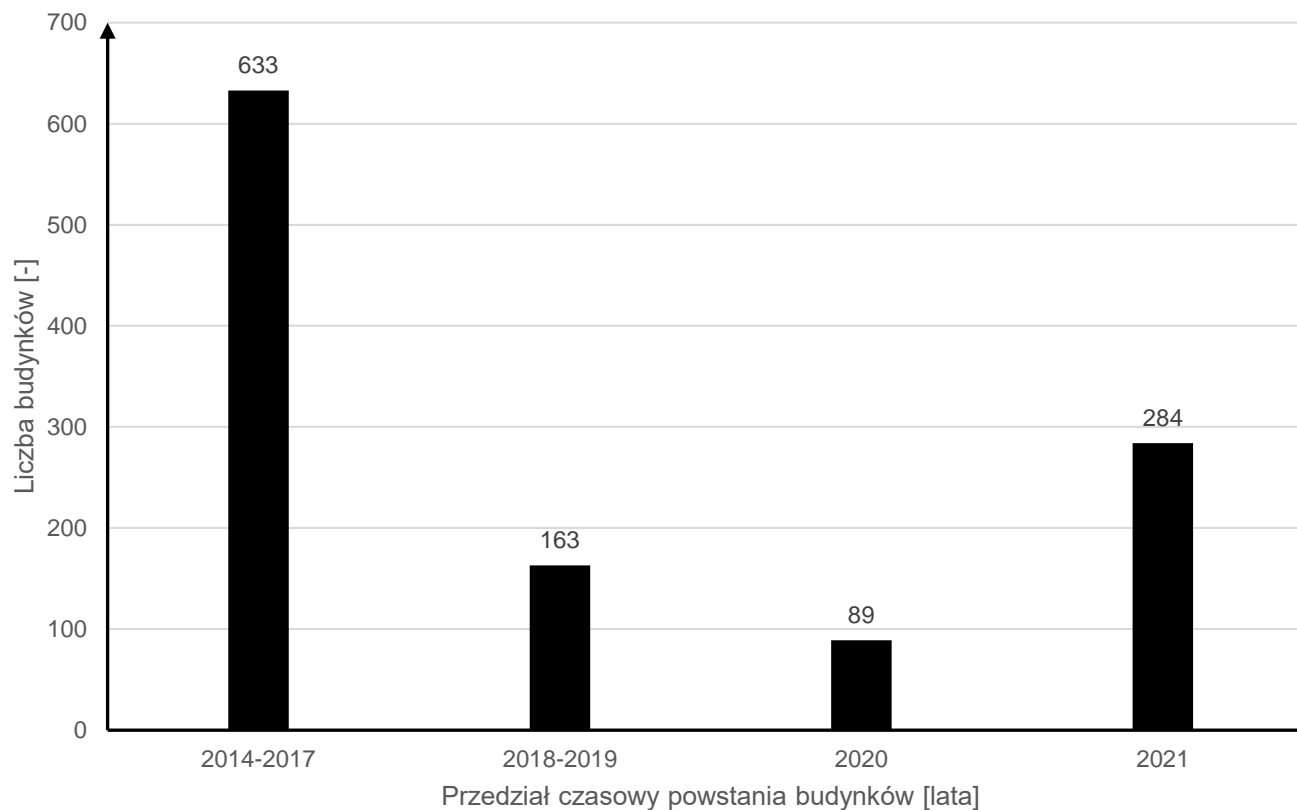


Wykorzystując narzędzie „*Detect Objects Using Deep Learning*” wykryto łącznie 22081 zabudowań





Budynki klasyfikowane jako nowopowstałe





Średnia ufność wyznaczenia nowych budynków

Rocznik/Obszar	N-34-49-B-d-2-3	N-34-50-C-a-1-2	N-34-50-D-b-1-2	Średnia:
2014-2017	87,8%	88,9%	90,9%	89,2%
2018-2019	91,7%	89,0%	93,1%	91,3%
2020	91,7%	88,0%	86,5%	88,7%
2021	88,5%	87,7%	84,8%	87,0%
Średnia:	89,9%	88,4%	88,8%	89,0%



Wstęp

Automatyczna detekcja zabudowań

Wyznaczenie przedziału czasowego

Wyniki

Wnioski



**Niniejsza praca udowodniła, że wykorzystanie narzędzi
głębokiego uczenia na ortofotomapach umożliwia
wyznaczanie przedziałów czasowych powstawania
budynków.**



Przy kilku modyfikacjach procesu można uzyskać dodatkowe dane dotyczące wyburzeń, braku zmian lub innych zależnościach pomiędzy danymi wektorowymi.



W celu wykorzystywania przedstawionej metody do aktualizacji baz danych wektorowych:

- **Ortofotomapy powinny być aktualizowane jak najczęściej,**
- **Istotna jest rozdzielczość terenowa,**
- **Dane powinny być ogólnodostępne i darmowe.**



Możliwości rozwoju metody:

- **Wykorzystanie danych LiDAR do efektywniejszego rozróżniania budynków,**
- **Wykrywanie innych elementów terenu i infrastruktury np. dróg, drzew, parceli**



HISTORIA MĄDROŚCIĄ
PRZYSZŁOŚĆ WYZWANIEM